

Informe Final

Fortalecimiento de capacidades instaladas de Ciencia y Tecnología para atender problemáticas asociadas con agentes biológicos de alto riesgo para la salud humana en el departamento del Magdalena

El presente informe es referente a las actividades:

Actividad 12.6: Aplicación de métodos de aprendizaje de máquina para el análisis de imágenes médicas (tomografías computarizadas de tórax con alta resolución) como complemento del diagnóstico y control de los pacientes de COVID-19.

Actividad 12.7: Análisis de datos epidemiológicos con métodos de aprendizaje de máquina que permitan simular y predecir escenarios de riesgo para apoyar la toma de decisiones.

Desarrollo de la actividad 12.6

La actividad 12.6 fue desglosada en más actividades, las cuales se fueron desarrollando por etapas:

Actividad 12.6.1 Revisión de referentes de métodos computacionales para diagnosticar Covid-19 a partir de imágenes médicas.

Algunos métodos de diagnóstico alternativo de COVID-19 incluyen análisis clínico del historial epidemiológico en imágenes radiométricas, tales como tomografías computarizadas de tórax (TCT) y radiografía de rayos X de tórax (RT) [1].

Las imágenes radiométricas son una importante herramienta debido a que la mayoría de los casos de COVID-19 presentan características similares tales como: opacidades de vidrio Esmerilado (OVE), también llamado opacidades de vidrio deslustrado (OVD), se observa como una opacidad parenquimatosa pulmonar, sin embargo, a pesar del aumento de densidad se siguen diferenciando los vasos pulmonares y las paredes de los bronquios del parénquima afectado. En las imágenes médicas de pacientes con Covid-19 también se puede observar consolidación pulmonar que consiste en la ocupación del espacio aéreo por productos patológicos tales como pus, agua, o sangre, entre otros. La consolidación se observa como un aumento homogéneo de densidad que oculta los márgenes de los vasos y las paredes de las vías respiratorias. Por último, también se debe mencionar los patrones en empedrados que se pueden observar en las TCT que se caracterizan por un engrosamiento de los septos inter e intralobulillares superpuesto a las OVE, simulando un suelo de adoquines [2]. Otros hallazgos de patrones en imágenes de pacientes con Covid-19 con menor incidencia en los distintos estudios son el engrosamiento de septos interlobulillares, las bronquiectasias, el engrosamiento pleural, el predominio de la afectación bilateral de lóbulos inferiores y la localización periférica y posterior [3].

La revisión de métodos computacionales para detectar los patrones antes mencionados en imágenes médicas de paciente de Covid-19 están basados principalmente en inteligencia artificial. La mayoría de los métodos encontrados utilizan de redes neuronales de convolución (CNN), las cuales se constituyen como un método de aprendizaje de máquinas profundo que ha probado muy buen desempeño para extraer características de las imágenes y a partir de ellas realizar clasificación. La Tabla 1 resume los métodos revisados para esta actividad. La mayoría de los métodos revisados reportan más de un 90% de precisión en la clasificación como positivo de imágenes de pacientes con Covid-19.

Tabla1. Métodos computacionales revisados para diagnosticar Covid-19 a partir de imágenes médicas.

Artículo	Autores	Fecha	Método
COVID-Net: a tailored deep convolutional neural network design for detection of COVID-19 cases from chest X-ray images [4]	Wang, Qiu Lin, y Wong	Novi 11, 2020	Covid-Net, convolución, kernels de diferentes tamaños y agrupamiento, GSInquire
Covid-19: automatic detection from X-ray images utilizing transfer learning with convolutional neural networks [7]	Apostolopoulos, I. and Mpesiana, T.	Abril 3,2020	Transfer learning con: VGG-19, MobileNet V2, Inception V4, Xception, Inception ResNet V2
Automatic Detection of Coronavirus Disease (COVID-19) Using X-ray Images and Deep Convolutional Neural Networks [8]	Narin, A., and Kaya, C., and Pamuk, Z.	Octu 5, 2020	Evalua modelos pre-entrenados: ResNet50, ResNet101, ResNet102, Inception V3, Inception ResNet V2
Classification of COVID-19 in chest X-ray images using DeTraC deep convolutional neural network [9]	Abbas, A., and Abdelsamea, M., and Gaber, M.	Septi 5,2020	DeTraC (Decomposition, transfer, composition). En la etapa de transfer learning evalua diferentes modelos: AlexNet, VGG19, ResNet, GoogleNet, y SqueezeNet
COVIDiagnosis-Net: Deep Bayes-SqueezeNet based diagnosis of the coronavirus disease 2019 (COVID-19) from X-ray images [10]	Ucar y Korkmaz	Abril 21, 2020	Un modelo Bayes-SqueezeNet llamado COVIDiagnosis-Net. Aplica optimización bayesiana para ajustar los hiperparámetros del modelo
Can AI Help in Screening Viral and COVID-19 Pneumonia? [5]	Chowdhury, and M. Rahman, T., et. al.	Julio 30,2020	Evalua el efecto de image augmentation sobre 8 modelos: SqueezeNet, MobileNet V2, ResNet 18, Inception V3, ResNet 101, ChexNet, DenseNet 201, VGG19

COVID-CAPS: A capsule network-based framework for identification of COVID-19 cases from X-ray images [11]	Afshar, P. and Heidarian, S., et al	Abril 16, 2020	Covid-CAPS, aplica pre-entrenamiento, y transferencia de aprendizaje sobre un conjunto de imagenes externa de imagenes X-ray con enfermedades toraxicas comunes. La diferencia con los demás modelos está en que no utiliza ImgeNet, si no imágenes de torax de naturaleza similar
Deep-COVID: Predicting COVID-19 from chest X-ray images using deep transfer learning [12]	Minaee, S. and Kafieh, R., et al.	Julio 21, 2020	Evaluan: ResNet18, ResNet50, SqueezeNet, y DenseNet121. preparan un dataset of 5,000 Chest X-rays.
Accurate prediction of COVID-19 using chest x-ray images through deep feature learning model with smote and machine learning classifiers [13]	Kumar, R., and Arora, R., et al.	Abril 17, 2020	Un modelo por etapas, Deep feature learning + SMOTE + ML classifier. Para la primera parte utiliza ResNet152, la segunda es para balancear el dataset, y la 3ra utiliza random forest y XGBoost
Automatic detection of COVID-19 using X-ray images with deep convolutional neural networks and machine learning [6]	S. Asif, Y Wenhui	Junio 18, 2020	Un modelo CNN basado en transfer learning con Inception V3

Se encontró que la mayoría de los métodos implementaron transfer learning, esto es la utilización de modelos pre-entrenados para resolver tareas de clasificación similar que fueron adaptados al caso de la detección de Covid-19. Transfer learning es una forma de ahorrar costo computacional en modelos complejos como lo son los propuestos en el aprendizaje profundo. Por ejemplo [6] utiliza el modelo de red neuronal profunda Inception V3, la cual es ampliamente utilizada y reconocida para tareas de reconocimiento de objetos, y clasificación de imágenes. Este modelo es utilizado a través de transfer learning, y se utiliza como capa de salida basada en softmax. El trabajo presentado por Wang et al. [4] está inspirado en las arquitecturas de las redes neuronales VGG-19 y ResNet-50, y entrenan un modelo llamado COVID-Net sobre un dataset llamado COVIDx, el cual está conformado con 13.975 imágenes de pacientes con Covid-19, con infecciones pulmonares diferentes a Covid-19, y personas sin infección. En [5] Chowdhury et al. evalúan ocho modelos diferentes de redes neuronales profundas expuestos en la literatura para reconocimiento de objetos y clasificación, para identificar imágenes provenientes de casos positivos de Covid-19 y neumonía, los modelos fueron: MobileNet-v2, SqueezeNet, ResNet-18, Inception-v3, ResNet-101, CheXNet, VGG-19, y DenseNet-201.

Actividad 12.6.2 Búsqueda de bases de datos con imágenes de pruebas para evaluar los diferentes métodos de diagnósticos a partir de imágenes propuestos en la literatura

En el desarrollo de esta actividad se recolectaron imágenes RT de diversas fuentes y repositorios. En la Tabla 2 se listan las fuentes públicas de donde se hizo la recolección:

Tabla 2. Fuentes de las imágenes RT recopiladas para la elaboración de la actividad 12.6

Nombre	Fuente	Descripción
COVIDx-iMICS Lung Segmentation Dataset [14]	https://github.com/samxmot/RANDGAN	Es un dataset construido a partir de otras fuentes públicas tal como covid-chestxray-dataset, Actualmed COVID-19 Chest X-ray Dataset Initiative, COVID-19 Radiography Database de Kaggle,
COVIDXDataset	https://github.com/jdariasl/COVIDNET/tree/master/COVIDXDataset	Es un repositorio de imágenes RT para la detección de Covid-19 basado en CovidNet, e incluyen diferentes pasos de preprocesamiento tales como cropping y segmentación de la cavidad pulmonar.
COVID-19 chest xray	https://www.kaggle.com/bachrr/covid-chest-xray	Es un conjunto de imágenes RT y TCT de casos de Covid-19 y también incluye casos de MERS, SARS, and ARD
Chest X-Ray Images (Pneumonia)	https://www.kaggle.com/paultimothy/mooney/chest-xray-pneumonia	Una colección de 5863 imágenes de RT de pacientes con neumonía y sin neumonía (normales).
NIH Chest X-ray	https://academictorrents.com/details/557481faacd824c83fbf57dcf7b6da9383b3235a	Contiene imágenes con 14 categorías de enfermedades torácicas comunes.

Todas las fuentes de imágenes consultadas en la Tabla 2 son open source, de estas fuentes se conformó un conjunto de imágenes para trabajar en esta actividad constituido de la siguiente manera:

Tabla 3. Conjunto de imágenes públicas recopiladas para la elaboración de la actividad 12.6

Categoría	Número de imágenes
Pacientes positivos con Covid-19	10000
Imágenes de personas normales	15000
Pacientes con neumonía debido a otra causa distinta de Covid-19	11000

Actividad 12.6.3 Evaluación de los diferentes métodos encontrados, y selección de acuerdo con ciertos criterios de desempeños seleccionados

Se implementaron y evaluaron un total de 12 arquitecturas diferentes de redes neuronales profunda, de las cuales algunas de ellas se describen a continuación. Cada uno de los modelos se entreno y evalúo sobre subconjuntos de imágenes conformados a partir de la recopilación de casos realizado en la actividad anterior.

SqueezeNet

Se realizó el desarrollo computacional de la red neuronal SqueezeNet, basados en la literatura, con el uso de una base de datos que contiene 3 clases: Covid, normal y neumonía viral. Para esto se trabajó en el entorno de desarrollo Visual Studio Code con el uso de las herramientas del lenguaje de programación Python en un Jupyter notebook y con el desarrollo de la red neuronal implementada.

Con base a estos resultados, se procedió a realizar la matriz de confusión para las tres clases en la base de datos de prueba, obteniendo los resultados mostrados en la imagen 2.




Figura 1. Matriz de confusión del modelo SqueezeNet, cuyo porcentaje de acierto fue de 95%




Figura 2. Arquitectura de SqueezeNet

https://www.researchgate.net/figure/SqueezeNet-CNN-Architecture_fig1_306003694

CovidNet

Se realizó el desarrollo computacional de la red neuronal CovidNet, basados en la literatura, con el uso de una base de datos que contiene 3 clases: Covid, normal y neumonía viral. Para esto se trabajó en el entorno de desarrollo Visual Studio Code con el uso de las herramientas del lenguaje de programación Python en un Jupyter notebook y con el desarrollo de la red neuronal realizado:

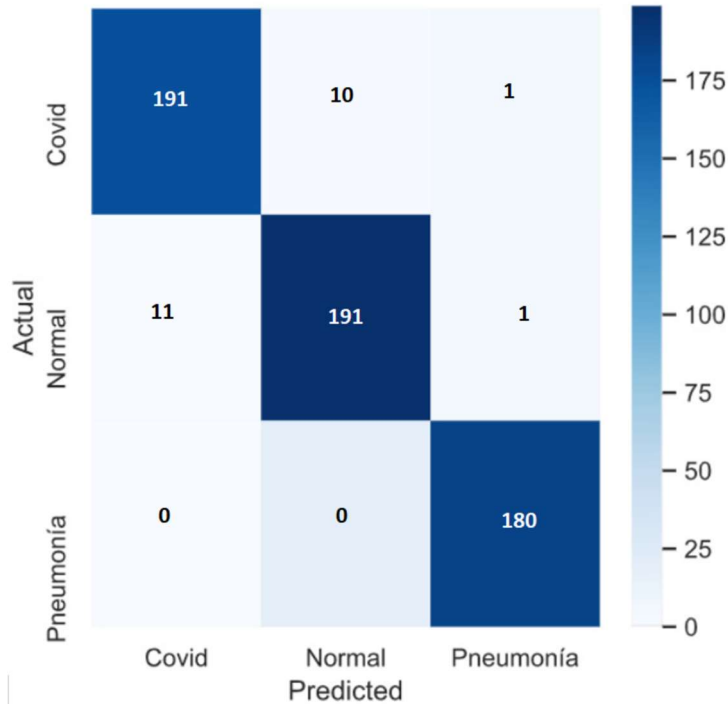


Figura 3. Matriz de confusión del modelo CovidNet, cuyo porcentaje de acierto fue de 96%

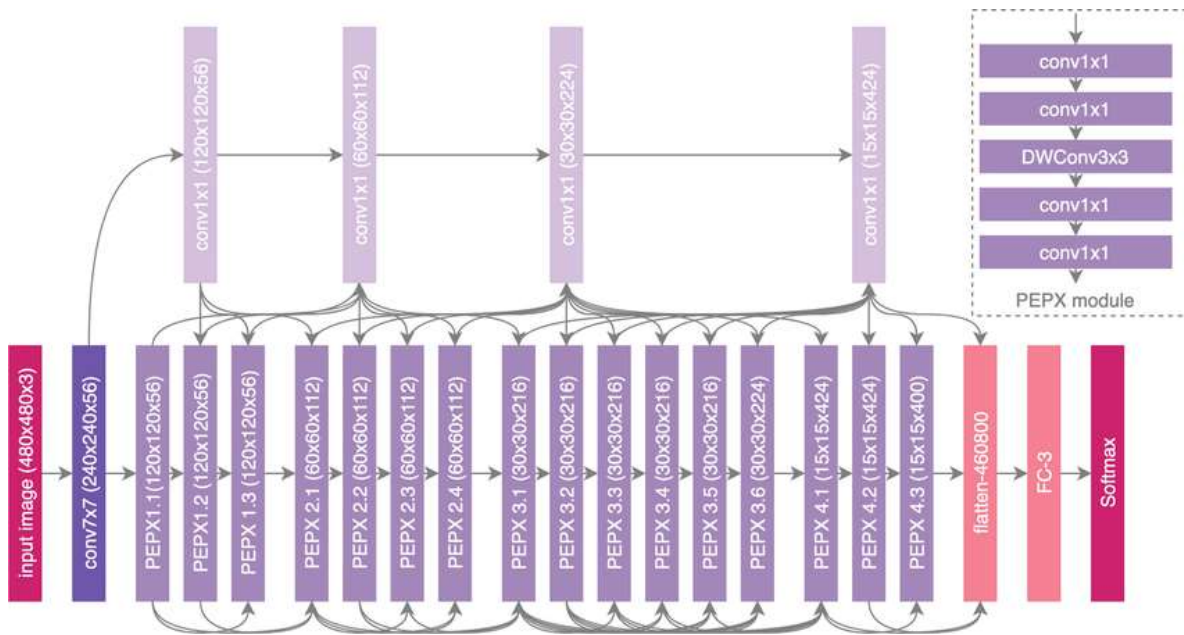


Figura 4. Arquitectura de COVID-Net

https://www.researchgate.net/figure/COVID-Net-architecture-High-architectural-diversity-and-selective-long-range_fig5_346521704

Se realizó el desarrollo computacional de la red neuronal ResNet50, basados en la literatura, con el uso de una base de datos que contiene 3 clases: Covid, normal y neumonía viral. Para esto se trabajó en el entorno de desarrollo Visual Studio Code con el uso de las herramientas del lenguaje de programación Python en un Jupyter notebook y con el desarrollo de la red neuronal realizado




Figura 5. Matriz de confusión del modelo ResNet50, cuyo porcentaje de acierto fue de 94.18%

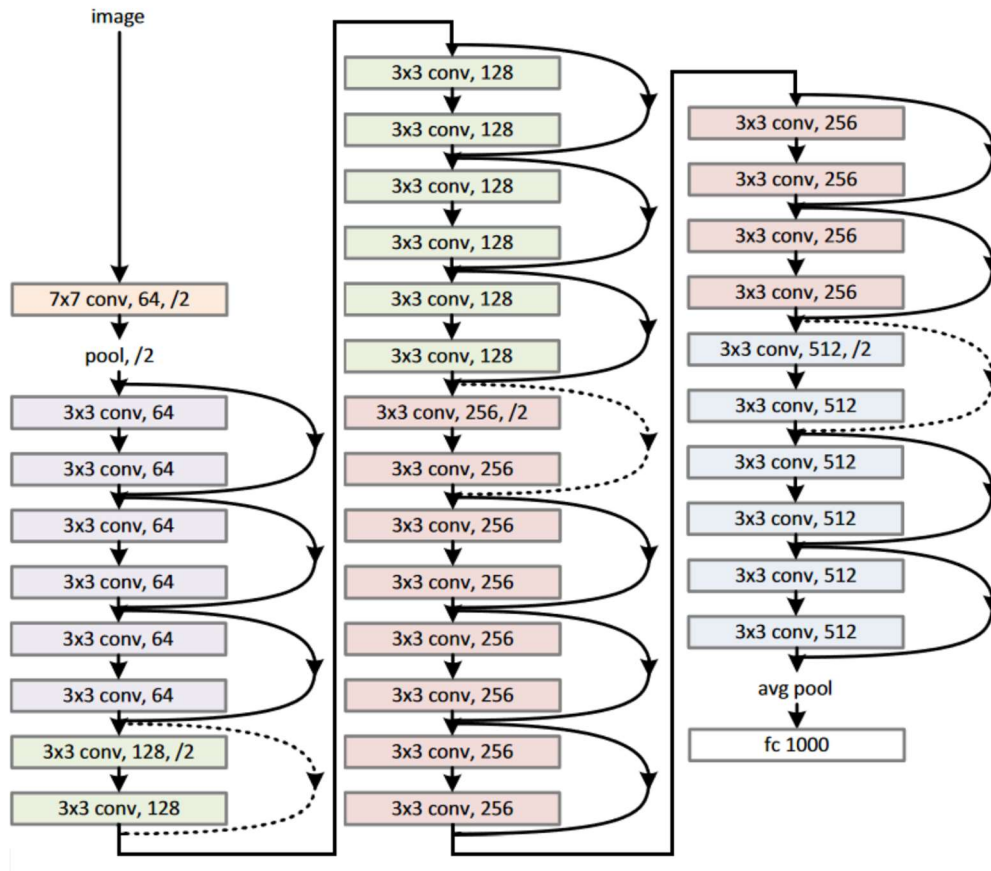


Figura 6. Arquitectura de ResNet50

DenseNet

Se realizó el desarrollo computacional de la red neuronal DenseNet, basados en la literatura, con el uso de una base de datos que contiene 3 clases: Covid, normal y neumonía viral. Para esto se trabajó en el entorno de desarrollo Visual Studio Code con el uso de las herramientas del lenguaje de programación Python en un Jupyter notebook y con el desarrollo de la red neuronal realizado en la librería Pytorch. Se realizó la arquitectura de la DenseNet de acuerdo con la literatura, y con ella se procedió a entrenar el sistema con imágenes de entrenamiento distribuidas de la siguiente manera: 840 imágenes de Covid, 937 imágenes normales y 942 imágenes de neumonía viral. A partir de esto, se realizó un entrenamiento de 30 epochs con un batch size de 128, como se muestra en la imagen 1 y se llegó a una precisión en la base de datos de entrenamiento de hasta 99.52%.




Figura 7. Matriz de confusión del modelo DenseNet, cuyo porcentaje de acierto fue de 98.8%

En base a estos resultados, se procedió a realizar la matriz de confusión para las tres clases en la base de datos de prueba, obteniendo los resultados mostrados en la imagen 2.

A partir de estos resultados llegamos a una precisión en la base de datos de prueba de 97.95%, lo que es un buen resultado que supera trabajos previos como el de CovidNet, con el cual se llegó a valores de precisión de has un 96%.

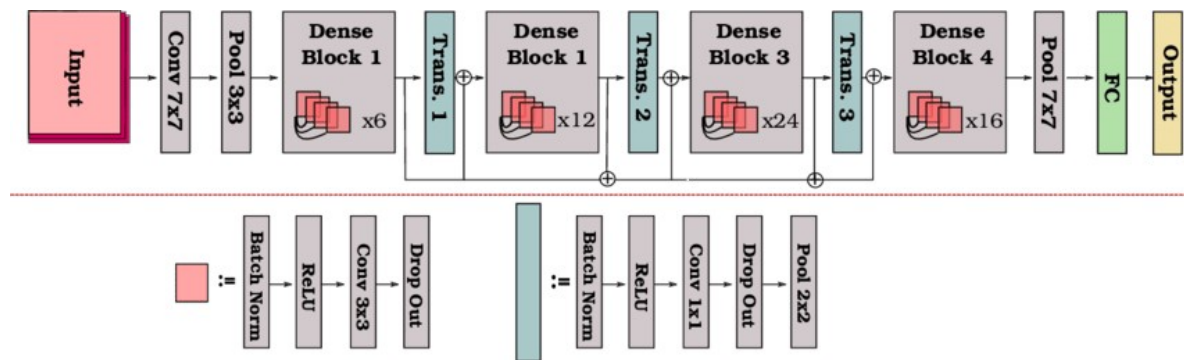


Figura 8. Arquitectura de DenseNet

https://www.researchgate.net/figure/A-schematic-illustration-of-the-DenseNet-121-architecture-82_fig5_334170752/download

12.6.4. Selección de un conjunto de imágenes médicas provenientes de diferentes fuentes de casos de Covid-19 en el departamento del Magdalena

Reiteradamente se solicitaron el acceso a imágenes médicas de la red hospitalaria del Departamento del Magdalena; pero no fue posible la adquisición de algún tipo de imágenes. Durante la recopilación de las imágenes se logró mayor acercamiento con el hospital San Cristóbal del municipio de Ciénaga, y el hospital universitario Julio Méndez Barreneche; sin embargo, se presentaron múltiples inconvenientes para el acceso a las imágenes, en el caso del hospital del municipio de Ciénaga, se contaba con un repositorio de muchos archivos de imágenes en las que no era posible identificar pacientes por el tipo de enfermedad por la cual se había tomado las imágenes médicas. En el caso del hospital universitario Julio Méndez Barreneche, se alegó la imposibilidad del uso de las imágenes médicas debido a que no se tenía autorización de los pacientes para la utilización de las mismas con un propósito distinto al diagnóstico por fuera del hospital.

Se adjunta a este informe como evidencia varias solicitudes realizadas la Secretaria de Salud Departamental de su apoyo para acceder a las imágenes médicas requeridas para la evaluación de los modelos de predicción implementados en este proyecto, con casos de pacientes del Departamento.

También se implementaron y evaluaron las arquitecturas de redes neuronales profunda listadas a continuación:

Vgg19
MobileNet
AlexNet
EfficientNet
InceptionV3
RexNet
Inception-ResNet
Xception

12.6.5. Evaluación y análisis de los resultados obtenidos en la actividad 12.6.4.

La evaluación de los modelos implementados se llevó a cabo con imágenes de pacientes con afectaciones pulmonares, por Covid 19, por otras enfermedades, y pacientes sanos recopiladas a través de diferentes repositorios de imágenes reportados en la literatura. Las imágenes recopiladas en el desarrollo de la actividad 12.6.2 se dividió en un conjunto de imágenes para entrenamiento de los modelos y otro de prueba. En la Tabla 4 se presenta un resumen de las métricas de evaluación de los modelos que se implementaron sobre imágenes reservadas para pruebas. A diferencia de los resultados individuales mostrados en la sección anterior de este documento, los resultados de la Tabla 4 fueron obtenidos sobre un mismo subconjunto de imágenes de prueba.

Tabla 4. Métricas de evaluación de los modelos implementados sobre imágenes de prueba

model	Accuracy	Sensitivity	Specificity	PPV	NPV	F1_Score
Vgg19	98,65	99,45	97,95	97,67	99,52	98,55
Densenet	98,96	98,95	98,98	98,86	99,06	98,90
Mobilenet	98,87	99,13	98,64	98,52	99,19	98,82
Efficientnet	98,86	98,68	99,02	98,94	98,78	98,81
InceptionV3	87,60	91,15	80,42	90,39	81,80	90,77
Resnet	98,54	98,08	98,96	98,86	98,25	98,47
Rexnet	97,06	97,13	96,99	96,71	97,37	96,92

En esta tabla se puede observar la alta precisión de los modelos implementados para diagnosticar imágenes de rayos X de pacientes con Covid 19. El mejor desempeño entre todos los modelos lo obtuvo Densenet; mientras que la precisión más baja la obtuvo Inception V3. En promedio se obtuvo acierto por encima del 96% de todos los modelos, lo cual muestra estas herramientas alternativas de diagnóstico viables para brindar apoyo en la práctica médica.

12.6.6. Diseño e implementación del prototipo final

Los modelos implementados se pueden aplicar a imágenes médicas de pacientes con Covid-19 para su diagnóstico a través de una interfaz de usuarios que conforma el prototipo final de una aplicación de software para el diagnóstico de Covid-19 a partir de imágenes de rayos X.

La interfaz permite cargar una imagen para el diagnóstico y ejecutar los diferentes modelos implementados para obtener un diagnóstico. Permite ejecutar varios modelos a la vez entregando como resultado el diagnóstico que más coincidencia tenga entre todos los modelos, o se puede seleccionar un solo modelo para obtener el resultado.



Figura 9. Interfaz del prototipo de software desarrollado para diagnosticar Covid-19 a partir de imágenes de rayos X

Como resultado del diagnóstico realizado por la herramienta con base en los modelos de redes neuronales profunda implementados se muestra al usuario un porcentaje de que el caso en estudio pertenezca a la clase Normal, es decir, que se trata de un paciente sano, a la clase P neumonía, esto es, que el paciente presente anomalías en la imagen debido a P neumonía y no por afectaciones causadas por el Covid-19, o la clase Covid que implicaría que las anomalías encontradas en la imagen corresponden a un paciente con afectaciones en sus pulmones debido a esta enfermedad. La Figura 10 muestra el resultado final entregado por el prototipo de diagnóstico al analizar una imagen de prueba. Adicional a los porcentajes en que posiblemente el caso puede pertenecer a cada una de las tres clases, también se obtiene como resultado un mapa de calor en el que se puede observar las zonas de afectación en la imagen que conllevan al diagnóstico.




Figura 9. Diagnóstico del prototipo de software sobre una imagen de rayos X de prueba

La aplicación permite que este mapa de calor sea guardado como una imagen adicional a la imagen original.

Desarrollo de la actividad 12.7

Al igual que la actividad 12.6, esta actividad también se desglosó en un subconjunto de actividades que se detallaran a continuación.

Actividad 12. 7.1. Revisión estado del arte modelos de predicción de Covid-19, tanto en diagnóstico clínico como en el comportamiento de la pandemia.

Tabla 5. Resumen revisión bibliográfica métodos empleados para diagnósticos a partir de datos y síntomas del paciente.

Autor	Título del artículo	Métodos usados	Tipos de variables
Kim, Han, etal., 2020 [15]	An Easy-to-Use Machine Learning Model to Predict the Prognosis of Patients With COVID-19: Retrospective Cohort Study	3 XGBoost gradient boosting machine models 1 fixed grid of generalized linear models 1 default random forest 5 prespecified H2O gradient boosting machines, 1 near-default deep neural network, 1 extremely randomized forest, 1 random grid of XGBoost gradient boosting machines, 1 random grid of H2O gradient boosting machines, a random grid of Deep neural network models.	Demográficas: (Sexo, Edad); Temperatura; Síntomas; Comorbilidades; Actividades diarias (Independiente, parcialmente independiente, totalmente independiente)
Ikemura, Goldstein, etal., 2021 [16]	Using Automated-Machine Learning to Predict COVID-19 Patient Mortality	Gradient boosting machine extreme Gradient boosting (XGBoost), General linear models (GLM) Random forest (RF) Deep learning (DL). stacked ensemble models	Demográficas: (Sexo, Edad, Raza); Comorbilidades; síntomas físicos; laboratorios clínicos

Li, Ma, et al., 2020 [17]	Using machine learning of clinical data to diagnose COVID-19: asystematic review and meta-analysis	XGBoost gradient boosting machine models	Edad, sexo, niveles séricos de neutrófilos (continuos y ordinales), niveles séricos de leucocitos (continuos y ordinales), niveles séricos de linfocitos (continuos y ordinales), resultado de tomografías computarizadas, resultado de radiografías de tórax, síntomas notificados (diarrea, fiebre, tos, dolor de garganta, náuseas y fatiga), temperatura corporal y factores de riesgo subyacentes (enfermedades renales y diabetes).
Yan, Zhang, et al., 2020 [18]	Prediction of survival for severe Covid-19 patients with three clinical features: development of a machine learning-based prognostic model with clinical data in Wuhan	XGBoost gradient boosting machine models	Edad, Sexo, síntomas clínicos, historia epidemiológica, gravedad de la enfermedad
Gao, Cai, et al., 2020 [19]	Machine learning based early warning system enables accurate mortality risk prediction for COVID-19	support vector machine (SVM) ; support vector machine (SVM) ; neural network (NN) ; K-nearest neighbor (KNN) ; random forest (RF)	Edad, Sexo, síntomas clínicos, comorbilidades
Zoabi, Deri-Rozov, et al., 2021 [20]	Machine learning-based prediction of COVID-19 diagnosis based on symptoms	gradient-boosting machine model	Sexo, Mayor a 60, contacto con infectado, tos, fiebre, dolor de cabeza, dolor de garganta y falta de respiración

Actividad 12.7.2. Revisión de que tipo de información para predicción se puede recopilar para la implementación de los modelos predictivos revisados en la actividad 12.7.1. en el departamento del Magdalena.

Para la realización de esta actividad se solicitó a la Secretaría de Salud Departamental el acceso a historias clínicas de pacientes diagnosticados con Covid en las diferentes

instituciones que conforman la red hospitalaria del departamento. Se recibieron historias clínicas de pacientes de las siguientes E.S.E.

Tabla 6. Número de casos o historias clínicas que fueron remitidas desde hospitales del departamento.

E.S.E	No. De historias clínicas o casos
Hospital Luisa Santiago Márquez Iguarán de Aracataca	29
Hospital Cerro de San Antonio	5
Hospital Local de Remolino	5
Hospital Local de Concordia	28
Hospital Rafael Paba Manjarrez de San Sebastián de Buentaventura	37
Hospital San Cristóbal de Ciénaga	1644

De estas historias clínicas se extrajeron campos o información común en todas las historias, que de acuerdo con la revisión presentada en la Tabla 5 se pudiera utilizar como variables predictoras. En la depuración de historias o casos clínicos con toda la información completa, incluyendo el diagnóstico de Covid-19 positivo o no, solo solo se lograron recopilar 1332 casos. El siguiente listado muestra la información o variables comunes que se pudieron extraer de las historias clínicas disponibles:

Tabla 7. Variables predictoras o características que se extrajeron de las historias clínicas suministradas.

Edad
Sexo
Tos
Fiebre
Dificultad_Respiratoria
Fatiga
Odinofagia
Cefalea
Rinorrea
Diarrea
Hipertension
Diabetes
Obesidad
Enfermedades_Respiratorias
Asma
Fumador
Enf_Cardiaca

Cancer
Ins_Renal
Resultado

De esta manera, se recopiló un conjunto de datos para entrenamiento de modelos de predicción con 1332 casos, y 20 variables predictoras o atributos de pacientes de algunos hospitales del departamento del Magdalena.

Actividad 12.7.3. Recopilación de datos para aplicación de modelos de predicción

El único hospital con datos disponibles, que contaban con un diagnóstico positivo o negativo para Covid-19 fue el hospital San Cristóbal del cual se extrajeron los casos para construir un conjunto de datos para entrenamiento y prueba.

El conjunto final de datos con el cual se trabajó contiene 597 casos con diagnóstico negativo y 735 casos positivos. En la Tabla 8 se muestra la frecuencia de los síntomas que se encontró en este conjunto de datos:

Tabla 8. Síntomas frecuentes encontrados

Síntomas	Frecuencia
TOS	604
FIEBRE	471
DR	301
FATIGA	229
ODINOFAGIA	134
CEFALEA	103
ASINTOMATICO	82
DIFICULTAD RESPIRATORIA	80
RINORREA	55
DIARREA	51
FATIGA O ADINAMIA	37
ADINAMIA	12

Actividad 12.7.4. Evaluación de los diferentes métodos encontrados, y selección de acuerdo con ciertos criterios de desempeños seleccionados

Se evaluaron diferentes modelos utilizando la plataforma H2O y su componente AutoML, que permiten automatizar la selección del modelo, la generación de características, el ajuste de parámetros y la evaluación de los diferentes modelos. Por defecto esta herramienta entrena y evalúa modelos utilizando los siguientes métodos: Distributed Random Forest (DRF), Generalized Linear Model con regularización (GLM), modelos de redes neuronales con múltiples capas, completamente conectadas, y Extreme Gradient Boosting (XGBoost). La Figura 10 muestra los mejores modelos

encontrados por la plataforma H2O, en la que se puede observar un error cuadrático medido de 0.2 aproximadamente, y que el método que mejor desempeño tuvo fue el GBM.

	model_id	auc	logloss	aucpr	mean_per_class_error	rmse	mse
	StackedEnsemble_BestOfFamily_8_AutoML_1_20211206_110525	0.670823	0.642664	0.697716	0.40968	0.475283	0.225894
	GBM_grid_1_AutoML_1_20211206_110525_model_2359	0.666618	0.645256	0.683949	0.44042	0.47642	0.226976
	GBM_grid_1_AutoML_1_20211206_110525_model_3118	0.666051	0.645966	0.692449	0.453269	0.476867	0.227402
	GBM_grid_1_AutoML_1_20211206_110525_model_1224	0.665682	0.648473	0.692015	0.432455	0.477937	0.228424
	GBM_grid_1_AutoML_1_20211206_110525_model_2241	0.665235	0.647882	0.683653	0.440575	0.47765	0.228149
	GBM_grid_1_AutoML_1_20211206_110525_model_2820	0.665099	0.647826	0.694758	0.434508	0.477646	0.228146
	GBM_grid_1_AutoML_1_20211206_110525_model_1219	0.664806	0.646312	0.684193	0.436624	0.477017	0.227545
	GBM_grid_1_AutoML_1_20211206_110525_model_497	0.664734	0.646933	0.691103	0.451309	0.477234	0.227753
	GBM_grid_1_AutoML_1_20211206_110525_model_4109	0.664609	0.650781	0.690772	0.45582	0.478947	0.22939
	GBM_grid_1_AutoML_1_20211206_110525_model_1330	0.664196	0.646414	0.691723	0.437432	0.477079	0.227605

Figura 10. Métricas de error encontrados con los mejores modelos evaluados por la plataforma H2O.

Actividad 12.7.5. Adaptación de los métodos seleccionados en la actividad 12.7.4 para los datos recopilados en la actividad 12.7.3

El conjunto de casos de pacientes con sus síntomas recopilado, y depurado en la actividad 12.7.3 fueron particionados en un 80% para entrenamiento y un 20% para prueba. La función H2OAutoML de la plataforma utilizada se ejecutó con los siguientes parámetros:

```
aml = H2OAutoML(max_runtime_secs=7000, seed = 42, project_name = 'classification', balance_classes=True)
```

Figura 11. Ejecución de la función H2OAutoML con los datos recopilados

Actividad 12.7.6. Análisis de los resultados obtenidos en la actividad anterior

La siguiente figura contiene las métricas del mejor modelo seleccionado para la herramienta de diagnóstico alternativa que se obtuvo como resultado del desarrollo de estas actividades del proyecto:

```
ModelMetricsBinomial: gbm
** Reported on test data. **

MSE: 0.22652189044884255
RMSE: 0.47594315884235855
LogLoss: 0.6444827980878037
Mean Per-Class Error: 0.3678977272727273
AUC: 0.6470454545454545
AUCPR: 0.7204866926836274
Gini: 0.29409090909090909
```

Figura 11. Métricas de error del mejor modelo obtenido

Como se puede observar se obtuvo un error cuadrático medio de 0.2. Se hace la claridad que estos resultados están muy sujetos a los casos de pacientes entregados por el Hospital San Cristóbal del municipio de Ciénaga.

Actividad 12.6.8. Diseño e implementación del prototipo final

Se desarrollo una interfaz en la que se recolecta información de los síntomas seleccionados luego de analizar el mejor modelo de predicción obtenido. Al pulsar el botón diagnosticar se ejecuta el modelo GBM el cuál arroja un porcentaje de confianza de que el paciente padezca de Covid-19, o sea un caso negativo.

Diagnostico COVID

Caracterización y Sintamología

Caracterizacion

Sexo: Femenino

Edad: 0

¿Presenta algunos de estos sintomas?

- ☐ Fiebre
- ☐ Tos
- ☐ Dificultad Respiratoria
- ☐ Fatiga
- ☐ Odinofagia
- ☐ Dolor de cabeza
- ☐ Rinorrea
- ☐ Diarrea

Diagnosticar

Referencias

- [1] J. Y. Kim, P. G. Choe, Y. Oh, K. J. Oh, J. Kim, S. J. Park, J. H. Park, H. K. Na, and M. don Oh, *The first case of 2019 novel coronavirus pneumonia imported into korea from wuhan, china: Implication for infection prevention and control measures*, Journal of Korean Medical Science, 2020.
- [2] J. Cleverley, J. Piper, and M. M. Jones, *The role of chest radiography in con_rming covid-19 pneumonia*, The BMJ, vol. 370, 2020.
- [3] S. Salehi, A. Abedi, S. Balakrishnan, and A. Gholamrezanezhad, *Coronavirus disease 2019 (covid-19): A systematic review of imaging _ndings in 919 patients*, American Journal of Roentgentology, p. 7, 2020.
- [4] L. Wang, Z. Q. Lin, and A. Wong, *COVID-Net: a tailored deep convolutional neural network design for detection of COVID-19 cases from chest X-ray images*, Scientific Reports, vol. 10, no. 1, pp. 1-12, 2020.
- [5] M. E. Chowdhury, T. Rahman, A. Khandakar, R. Mazhar, M. A. Kadir, Z. B. Mahbub, K. R. Islam, M. S. Khan, A. Iqbal, N. A. Emadi, M. B. I. Reaz, and M. T. Islam, *Can AI Help in Screening Viral and COVID-19 Pneumonia?*, IEEE Access, vol. 8, pp. 132665-132676, 2020.
- [6] S. Asif and Y. Wenhui, *Automatic Detection of COVID-19 Using X-ray Images with Deep Convolutional Neural Networks and Machine Learning*, medRxiv, p. 020.05.01.20088211, 2020.
- [7] I. D. Apostolopoulos and T. A. Mpesiana, *Covid-19: automatic detection from X-ray images utilizing transfer learning with convolutional neural networks*, Physical and Engineering Sciences in Medicine, vol. 43, no. 2, pp. 635-640, 2020.
- [8] A. Narin and C. Kaya and Z. Pamuk, *Automatic detection of coronavirus disease (COVID-19) using X-ray images and deep convolutional neural networks*. Pattern Anal Applic 24, pp. 1207–1220, 2021.
- [9] A. Abbas and M.M. Abdelsamea and M.M Gaber, *Classification of COVID-19 in chest X-ray images using DeTraC deep convolutional neural network*. Appl Intell 51, pp. 854–864, 2021.
- [10] F. Ucar and D. Korkmaz, *COVIDiagnosis-Net: Deep Bayes-SqueezeNet based diagnosis of the coronavirus disease 2019 (COVID-19) from X-ray images*, Med Hypotheses 140, 2020.

- [11] P. Afshar and S. Heidarian and F. Naderkhani and A. Oikonomou and K. N. Plataniotis and A. Mohammadi, *Covid-caps: a capsule network-based framework for identification of covid-19 cases from x-ray images*, arXiv:2004.02696, 2020.
- [12] S. Minaee and R. Kafieh and M. Sonka and S. Yazdani and G. Jamalipour, *Deep-COVID: Predicting COVID-19 from chest X-ray images using deep transfer learning*, Medical Image Analysis 65, 2020.
- [13] R. Kumar and R. Arora and V. Bansal and V. J. Sahayasheela and H. Buckchash and J. Imran and N. N. and G. N. Pandian, and B. Raman, *Accurate Prediction of COVID-19 using Chest X-Ray Images through Deep Feature Learning model with SMOTE and Machine Learning Classifiers*, medRxiv Preprint posted online on April 17, 2020.
- [14] S. Motamed and P. Rogalla and F. Khalvati, *RANDGAN: Randomized Generative Adversarial Network for Detection of COVID-19 in Chest X-ray*, arXiv:2010.06418, 2020.
- [15] H. Kim and D. Han and J. Kim and D. Kim, *et al.*, *An Easy-to-Use Machine Learning Model to Predict the Prognosis of Patients With COVID-19: Retrospective Cohort Study*, J Med Internet Res, 2020.
- [16] K. Ikemura and E. Bellin and Y. Yagi and H. Billett and M. Saada and K. Simone and L. Stahl and J. Szymanski and D. Goldstein and M. Reyes, *Using Automated Machine Learning to Predict the Mortality of Patients With COVID-19: Prediction Model Development Study*, J Med Internet Res, 2021.
- [17] W. Li and J. Ma and N. Shende and G. Castaneda and J. Chakladar and J. Tsai and L. Apostol and C. Honda and J. Xu and L. Wong and T. Zhang and A. Lee and A. Gnanasekar and T. Honda, *et al.*, *Using machine learning of clinical data to diagnose COVID-19: a systematic review and meta-analysis*, BMC Med Inform Decis Mak, 2020.
- [18] L. Yan and H. Zhang and J. Goncalves and Y. Xiao and M. Wang and Y. Guo and C. Sun and X. Tang and L. Jin and M. Zhang and X. Huang and Y. Xiao and H. Cao and Y. Chen, *et al.* *Prediction of criticality in patients with severe Covid-19 infection using three clinical features: a machine learning-based prognostic model with clinical data in Wuhan*, medRxiv, 2020.
- [19] Y. Gao and G. Cai and W. Fang and H. Li and S. Wang and L. Chen and Y. Yu and D. Liu and S. Xu and P. Cui and S. Zeng and X. Feng and R. Yu and Y. Wang and Y. Yuan and X. Fei, *Machine learning based early warning system enables accurate mortality risk prediction for COVID-19*, Nature Communications, 2020.
- [20] Y. Zoabi and S. Deri-Rozov and N. Shomron, *Machine learning-based prediction of COVID-19 diagnosis based on symptoms*, NPJ Digit Med, 2021

